### NLTK: Natural Language Toolkit Overview and Application

Jimmy Lai

jimmy.lai@oi-sys.com

Software Engineer @ Oxygen Intelligence 2012/06/09





#### Outline

- 1. An application based on NLP: 聚寶評
- 2. Introduction to Natural Language Processing
- 3. Brief History of NLTK
- 4. NLTK





### 聚實評 www.ezpao.com

### 美食搜尋引擎



地區/地址/景點

店名/料理/食物,例如:拉麵...

找店家

地圖搜尋

選地點:縣市>鄉鎮市區

目前累積 99,575 種食物、2,706,720 筆短評,持續增加中...

### 搜尋各大部落格食記





### 聚實評 www.ezpao.com



新竹市

火鍋

找店家

地圖搜尋

選地點:縣市>鄉鎮市區

❸ 縮小搜尋範圍 (重設):

本次搜尋:在 新竹市 找 火鍋 的店家

語意分析搜尋引擎

約有 93 筆結果

田新路

上館新村

太和殿營養扁辣火鍋 300 新竹市經國路二段99號

網友分享標籤:綜合鍋類、連鎖店、麻辣火鍋

網友分享菜:鴛鴦麻辣火鍋、綜合菇盤、手工花枝漿 ... 共9道



短評共64筆



個人頭像:網路上也是好評不斷 還有人說比鼎王更好吃 看的我整個熱血沸騰啦!... 太和殿鴛鴦麻辣火鍋

2010/07/30

經驗分享: € 17 € 10 公 10





图 聚北海道昆布鍋新竹市中正路2號5樓

網友分享標籤:綜合鍋、謝師宴、大型團體聚會、火鍋 網友分享菜:梅子醋、昆布烏龍麵、精緻昆布鍋套餐 ... 共15道







wensuping:嚴選套餐甜品~金字塔紅豆冰堡,雖然天氣冷,但我還是堅持點這道~好食。...聚-北海道昆

布鍋 2011/01/06

經驗分享: € 21 € 0 公(3)











○ 台北林季扁辣火鍋連鎖店 新竹市民生路266號

網友分享標籤:綜合鍋類、麻辣火鍋、吃到飽

網友分享菜:麻辣鍋、鴛鴦鍋、酸白菜鍋、麻辣火鍋 ... 共15道



短評共79筆

hisldudi: 肉片/火鍋餃類/排骨酥/蛤蜊/鴨血豆腐/香菇丸 這些都挺推薦的。... [推薦][新竹市][麻辣火鍋] 林季麻辣火鍋 (新竹民生店) 2010/03/06

經驗分享:🙂/9 🖭 🕡 😭 🕡





搜尋地點:新竹市 店家排行榜



地图資料 @2012 Google, Kingway - 使用條款



火鍋

找店家

地圖搜尋

選地點:縣市>鄉鎮市區

<返回 本次搜尋結果

聚北海道昆布鍋 新竹市中正路2號5樓 [[[44]

電話:03-5260688 營業時間:

消費價位:一般價位

本店提供的服務: 450

經驗分享: 21 20 公3

■ 遷 0 図 歇 0

網友分享標籤:綜合鍋、謝師宴、大型團體聚會、節日聚會、綜合鍋類、家庭聚會

網友分享某:梅子醋(16) 、 昆布烏龍麵(16) 、 精緻昆布鍋套餐(13) 、 北海道金橙奶酪(11) 、 套餐(11) 、 蟹肉蒟蒻球(10) 、三色魚麵(10)、 北海道黃金稀飯(10)、 北海道昆布鍋套餐(9)、 精燉桂花赤豆饌(9)、 金字塔紅豆冰堡(9)、 嫩局牛

小排(9)、 豬雞雙拼主餐(8)、 昆布滋養湯(8)、 昆布麻辣湯(8)



96%



短評共595筆

#### 網友分享菜分析

短評共 595 筆

全部▼

搜尋文章內容: 請輸入關鍵字

全部時間 ▼ 資料來源

a

美味

全部主題





"聚"北海道昆布鍋 -- in新竹

cqovkrpe:↑手工創意單點:蝦仁福袋and山藥玉子燒雙拼↑服務人員建議點雙拼的可以吃到兩種 不同的東西 山藥玉子燒口感很Q...

內容

2009/12/17 很久以前

隨意窩

角頭海鮮主餐



新竹-聚北海道昆布鍋

阿叮:隔壁桌的秀華點了季節魚頭海鮮主餐 端來是大大的一隻魚頭和一些海鮮 看起來不錯吃旁 邊還有機罵和花枝 ...

正評/負評分析

2010/12/07 一年以前

蕃薯藤

美味



[家庭聚餐]生日聚 北海道昆布鍋

alice: 嫩晨牛小排是〔北海道嚴選套餐〕才有的主餐,它真的也沒讓我失望。均匀的油花分在的 肉耳上,放到鍋中涮幾下就熟了,入口軟嫩,滋味好呀!爸媽主餐選雞肉,雞肉也很不錯;而豬

肉是雪花豬,有特別的口感,也很不賴唷~ ...

2010/12/05 一年以前

新浪部落



[食·新竹] <sup>※</sup> 聚 <sup>※</sup> 在一起吃火鍋

aorange:北海道昆布鍋清清爽爽的,昆布滋卷鍋有中藥的味道, ...

2009/10/28 很久以前

愛評網

### 手機版

m.ezpao.com

網友分享菜:辣炒年糕

<u>看原文(愛評網)</u> - 2009/06/15

<u> 看原文(愛評網)</u> - 2009/07/01

<u> 看原文(愛評網)</u> - 2010/05/25

看原文(愛評網) - 2010/05/26

看原文(愛評網) - 2010/12/09

糖的地瓜鬆鬆綿綿, ...

<u> 看原文(愛評網)</u> - 2009/06/11

看原文(愛評網) - 2008/12/10

不會軟爛











0

#### 社群評論



網友分享菜單 編輯煎餅"(49)、拔緣地瓜(47)、辣炒年糕(18)、

銅盤烤肉鐵盤烤肉(9)、椒痲雞(10)、銅盤烤肉(10)













詩婷: 很推薦吃它的 "牛肉" 很嫩 很讚 還有它的位子真的很 少很少,所以想去吃的朋友們記得要事先打電話預約唷!!!否

看原文(愛評網) - 2010/06/23



小小庭:覺得這邊的店家應該要比較有質感一點!?韓聚算是 很樸實的一間店 不過連地板都好像不是很乾淨... 然後我想東 區地價真的太貴了能運用的空間都要發揮到極致廁所位於廚

看原文(愛評網) - 2010/06/25



sofia1002:櫃台設在這裡,最裡面是廚房,再來是廁所,就是櫃 台,其他都是座位區. 這裡真的很小一間...

看原文(愛評網) - 2010/05/27



愛吃的蛋蛋: 這裡的種類不多,但是也夠大家吃了,重點是調 味好還蠻好吃的,只是因為空間不太,所以只要有客人大聲那大 家的音量就要一起放大,像今天去吃的時候就碰到一組當這家 店是自己家的人客 ...

<u> 看原文(愛評網)</u> - 2010/12/22



**優娜的地盤**: 店小座位少,務必訂位 ...

<u> 看原文(痞客邦)</u> - 2009/11/05



~ming~:外面生意真的不錯!話說雖然對店家一直催促+限制 2小時的規定讓人覺得吃得很不盡興 還有店內空調實在有符 加強 (吃完回家 全身上下都是嚴重油煙味然後不知為何燒烤 過程湯汁噴得很厲害)...

看原文(愛評網) - 2009/07/18



joanne.chen:食材飲料區(其實我覺得東西並不多世...可能 是店內空間也真的不大)不定時地推出熱食

看原文(隨意窩) - 2009/08/26





#### 網友分享菜+正負評分析



看更多評論



### Natural Language Processing (NLP)

- 語音識別 (Speech recognition)
- 詞性標註 (Part-of-speech tagging)
- 句法分析 (Parsing)
- 自然語言生成(Natural language generation)
- 文本分類(Text classification)
- 信息抽取(Information extraction)
- 機器翻譯(Machine translation)
- 文字蘊涵(Textual entailment)





### NLTK: Natural Language Toolkit

- http://www.nltk.org/
- Author: Steven Bird, Edward Loper, Ewan Klein
- Originally developed for class student has background either in computer science or linguistics.
- Currently:
  - Education: over 100 courses in 23 countries.
  - Research: over 250 papers cites NLTK.





#### Outline

- 1. An application based on NLP: 聚寶評
- 2. Introduction to Natural Language Processing
- 3. Brief History of NLTK
- 4. NLTK:
  - a. Installation
  - b. Annotated Text Corpora
  - c. Text Tokenization, Normalization, Analysis, Distribution Analysis
  - d. Part-of-speech Tagging
  - e. Text Classification
  - f. Named Entity Recognition





### **Install NLTK**

Python 2.6+

pip install numpypip install matplotlibpip install nltk





## Annotated Text Corpora (1/3) nltk.corpus

- Corpus: 語料庫,含有某種結構化標記的資料集合,可能包含多種語言。
- 例如:
  - stopwords: 常見字字典
  - sinica\_treebank: 中文語句結構標記語料庫
  - brown: 包含15種分類及詞性標記的英語語料庫
  - wordnet: 包含詞性、同義反義的英語字典





### Annotated Text Corpora (2/3)

### nltk.corpus

```
import nltk
#download corpus on demand
nltk.download()

#stopwords
nltk.corpus.stopwords.words()
nltk.corpus.stopwords.words('english')
nltk.corpus.stopwords.words('french')

some_english_stopwords = ['most', 'me', 'below', 'when', 'which', 'what', 'of', 'it', 'very', 'our']
```

#Chinese treebank nltk.corpus.sinica\_treebank

#Examples (嘉珍, Nba) (和, Caa) (我, Nhaa) (住在, VC1) (同一條, DM) (巷子, Nab)

(我們, Nhaa) (是, V\_11) (鄰居, Nab)

(也, Dbb) (是, V\_11) (同班, Nv3) (同學, Nab)





### Annotated Text Corpora (3/3)

nltk.corpus

ACE Named Entity Chunker (Maximum entropy)

Australian Broadcasting Commission 2006

Alpino Dutch Treebank

BioCreAtIvE (Critical Assessment of Information

Extraction Systems in Biology)

**Brown Corpus** 

Brown Corpus (TEI XML Version)

**CESS-CAT Treebank** 

**CESS-ESP Treebank** 

Chat-80 Data Files

City Database

The Carnegie Mellon Pronouncing Dictionary (0.6)

ComTrans Corpus Sample

**CONLL 2000 Chunking Corpus** 

**CONLL 2002 Named Entity Recognition Corpus** 

Dependency Treebanks from CoNLL 2007 (Catalan

and Basque Subset)

Dependency Parsed Treebank

Sample European Parliament Proceedings Parallel

Corpus

Portuguese Treebank

**Gazeteer Lists** 

**Genesis Corpus** 

**Project Gutenberg Selections** 

**NIST IE-ER DATA SAMPLE** 

C-Span Inaugural Address Corpus

Indian Language POS-Tagged Corpus

JEITA Public Morphologically Tagged Corpus (in

ChaSen format)

**PC-KIMMO Data Files** 

KNB Corpus (Annotated blog corpus)

Language Id Corpus

Lin's Dependency Thesaurus

MAC-MORPHO: Brazilian Portuguese news text with

part-of-speech tags

Machado de Assis -- Obra Completa

Sentiment Polarity Dataset Version 2.0

Names Corpus, Version 1.3 (1994-03-29)

NomBank Corpus 1.0

**NPS Chat** 

**Paradigm Corpus** 





### Text Tokenization nltk.tokenize

#### Web Text Processing Flow

```
HTML
                            ASCII
                                               Text
                                                              Vocabulary
from urllib import urlopen
html = urlopen(url).read()
raw = nltk.clean html(html)
sents = nltk.sent tokenize(raw)
                                     # wordpunct tokenize: ['3', '.', '33']
tokens = []
                                     # word tokenize: ['3.33']
for sent in sents:
   tokens.extend(nltk.word tokenize(sent))
text = nltk.Text(tokens)
words = [word.lower() for word in text]
vocab = sorted(set(words))
```





### Text Normalization (1/2) nltk.stem

- Stem: 將單字(現在式、過去式、單複數)還原成原型。可以將不同形式的單字歸類為同一個單字。
- 著名演算法: Porter Stemmer





### Text Normalization (2/2) nltk.stem

```
In [1]: words = nltk.corpus.conll2000.words()[:20]
In [2]: print words
['Confidence', 'in', 'the', 'pound', 'is', 'widely', 'expected', 'to', 'take', 'another',
'sharp', 'dive', 'if', 'trade', 'figures', 'for', 'September', ',', 'due', 'for']
In [3]: stemmer = nltk.stem.PorterStemmer()
In [4]: print [stemmer.stem(word) for word in words]
['Confid', 'in', 'the', 'pound', 'is', 'wide', 'expect', 'to', 'take', 'anoth',
'sharp', 'dive', 'if', 'trade', 'figur', 'for', 'Septemb', ',', 'due', 'for']
In [5]: stemmer = nltk.stem.LancasterStemmer()
In [6]: print [stemmer.stem(word) for word in words]
['confid', 'in', 'the', 'pound', 'is', 'wid', 'expect', 'to', 'tak', 'anoth',
'sharp', 'div', 'if', 'trad', 'fig', 'for', 'septemb', ',', 'due', 'for']
In [7]: stemmer = nltk.stem.WordNetLemmatizer()
In [8]: print [stemmer.lemmatize(word) for word in words]
['Confidence', 'in', 'the', 'pound', 'is', 'widely', 'expected', 'to', 'take', 'another',
'sharp', 'dive', 'if', 'trade', 'figure', 'for', 'September', ',', 'due', 'for']
```





### **Text Analysis**

### nltk.text

```
#using sinica treebank dataset
     In [1]: text = nltk.Text(nltk.corpus.sinica treebank.words())
     #common context
     In [2]: text.common contexts(['是', '在'])
     一直_我 也_一 也_台北 也_她 他_一個 就_大 就_我們
     就 這 的 他 說 中國 都 樹
     #collocation
     In [3]: text.collocations()
     Building collocations list
     全 國; 國家 公園; 就 是; 身 上; 都 是; 才 能; 站 在;
     還 有; 最 大; 河 邊; 的 時候; 變 得; 心 裡; 這 是; 各
     地;帶著;院子裡;一個人;是一個;就會
     #concordance
     In [4]: text.concordance('台灣', lines=10)
     Displaying 10 of 161 matches:
     ?? IBMClub 的 組織 台灣 IBM 為 配合 國內 勞工
     ?? 男子 獨 專 成功 立名 的 台灣 為 女性 揚眉吐氣 她們 是
     ?? 智慧 的 她 女性 形象 在 台灣 和 中國 大陸 小說 是 解放
     腐 的 同時 在 雙十節 宣稱 台灣 要 以 統一 大業 為 己任?
     資源 的 條件 因為 今天 的 台灣 並 沒有 發展出 一個 具備
     有 一位 廣播 電視 廳長 是 台灣 基隆 人 一個 人 如果 已?
     ?? 粗俗 的 水泥 步道 時 在 台灣 經濟 發展 的 歷史 赤裸裸
2012 ?? 的 自然 的 力量 為 避免 台灣 原住民族 文化 特質 與 總?
     ?? 註 明 清 時期 漢人 嫁給 台灣 平埔族 女子 大部份 摻雜?
            上 看到 一則 介紹 台灣 近況 的 報導 尋找 自我 認
```



### Text Distribution Analysis

nltk.probability

```
In [1]: import nltk
In [2]: dist = nltk.probability.FreqDist(nltk.corpus.shakespeare.words('hamlet.xml'))
In [3]: dist.tabulate(20)
           the
                     and
                                                                           in HAMLET
                                 of
                                                     you
                                                                my
                                                          467
                                                               435
                                                                    417
3211 1289 996
               909
                     705
                           640
                                631
                                     606
                                          580
                                                519
                                                     497
                                                                          413
                                                                               389
                                                                                    362
                                                                                               300
In [4]: dist.plot(20)
In [5]: dist['the']
Out[5]: 996
In [6]: cdist = nltk.probability.ConditionalFreqDist(
            (len (word), word) for word in nltk.corpus.shakespeare.words('hamlet.xml'))
In [7]: float(cdist[3]['the']) / float(cdist[3].N())
Out[7]: 0.14619110523998238
                               3500
                               3000
                               2500
```



1500

1000

500



### Part-of-speech Tagging (1/3) nltk.tag

- Part of Speech Tagging: 詞性標記,標記每個單字的詞性。
- · 同一單字的不同詞性其語義不同, 如Book名詞是書,動詞是預定。
- 透過POS Tagging,可以賦予文字更 多語義資訊。

| Tag | Meaning      |
|-----|--------------|
| ADJ | adjective    |
| ADV | adverb       |
| CNJ | conjunction  |
| DET | determiner   |
| EX  | existential  |
| FW  | foreign word |
| MOD | modal verb   |
| N   | noun         |
| NP  | proper noun  |
| NUM | number       |
| PRO | pronoun      |
| Р   | preposition  |
|     |              |





### Part-of-speech Tagging (2/3) nltk.tag

```
In [1]: print nltk.corpus.brown.tagged_words()[:15]
[('The', 'AT'), ('Fulton', 'NP-TL'), ('County', 'NN-TL'), ('Grand', 'JJ-TL'),
('Jury', 'NN-TL'), ('said', 'VBD'), ('Friday', 'NR'), ('an', 'AT'),
('investigation', 'NN'), ('of', 'IN'), ("Atlanta's", 'NP$'), ('recent', 'JJ'),
('primary', 'NN'), ('election', 'NN'), ('produced', 'VBD')]

#an off-the-shelf tagger
In [2]: print nltk.tag.pos_tag(nltk.corpus.brown.words()[:15])
[('The', 'DT'), ('Fulton', 'NNP'), ('County', 'NNP'), ('Grand', 'NNP'), ('Jury', 'NNP'),
('said', 'VBD'), ('Friday', 'NNP'), ('an', 'DT'), ('investigation', 'NN'), ('of', 'IN'),
("Atlanta's", 'JJ'), ('recent', 'JJ'), ('primary', 'JJ'), ('election', 'NN'),
('produced', 'VBN')]
```





### Part-of-speech Tagging (3/3) nltk.tag





## Text Classification (1/3) nltk.classify

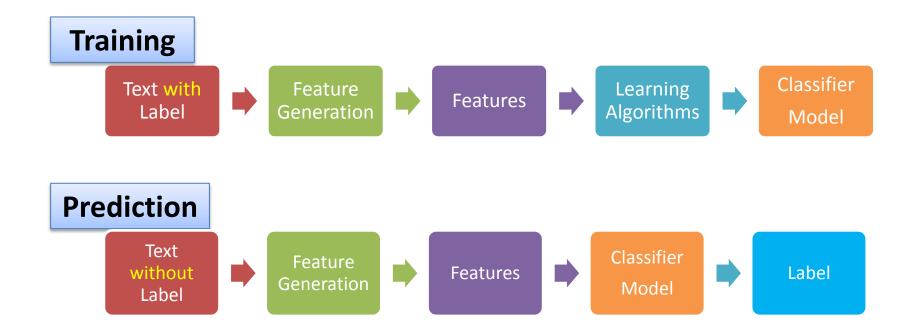
- Text Classification: 文字分類,分析文字後將 文字分到預先定義的類別裡。
- 基於統計的機器學習演算法,著名的演算 法為:
  - Naïve Bayes Classifier
  - Decision Tree
  - Support Vector Machine





## Text Classification (2/3) nltk.classify

#### Machine Learning Approach Work Flow







### Text Classification (3/3)

```
nltk.classify
In [1]: name label list = []
In [2]: name label list.extend([ (name, 'female') for name in nltk.corpus.names.words('female.txt')])
In [3]: name label list.extend([ (name, 'male') for name in nltk.corpus.names.words('male.txt')])
In [4]: random.shuffle(name label list)
In [5]: name label list[:5]
Out[6]:
[('Giffard', 'male'),
 ('Melosa', 'female'),
 ('Minerva', 'female'),
 ('Debora', 'female'),
 ('Adrien', 'male')]
In [7]: def get feature(name):
           features = {'first letter':name[0], 'last letter':name[-1],
   . . . :
                       'first 2 letter': name[:2], 'last 2 letter': name[-2:],
   . . . :
                       'first 3 letter': name[:3], 'last 3 letter': name[-3:]}
   . . . :
           return features
   . . . :
   . . . :
In [8]: feature set = [(get feature(name), label) for (name, label) in name label list ]
In [9]: size = int(len(feature set) * 0.9)
In [10]: train set, test set = feature set[:size], feature set[size:]
In [11]: classifier = nltk.classify.NaiveBayesClassifier.train(train set)
In [12]: nltk.classify.accuracy(classifier, test set)
Out[13]: 0.8377358490566038
             2012 TAIWAN
```

## Named Entity Recognition (NER) (1/2) nltk.tag, nltk.chunk

• Named Entity Recognition: 從文字中擷取出命名實體,命名實體是具有完整語義的複合單字。例如:人名、地名、事件。

# Sentence Segmentation Tokenization POS tagging Named Entity Recognition Recognition





### Named Entity Recognition (NER) (2/2) nltk.tag, nltk.chunk

```
In [1]: import nltk
In [2]: tagger = nltk.tag.stanford.NERTagger(
                 'stanford-ner-2012-05-22/classifiers/english.conll.4class.distsim.crf.ser.gz',
                 'stanford-ner-2012-05-22/stanford-ner-2012-05-22.jar')
In [3]: tagger.tag('Rami Eid is studying at Stony Brook University in NY'.split())
Out[3]:
[('Rami', 'PERSON'),
 ('Eid', 'PERSON'),
 ('is', '0'),
 ('studying', '0'),
 ('at', '0'),
 ('Stony', 'ORGANIZATION'),
 ('Brook', 'ORGANIZATION'),
 ('University', 'ORGANIZATION'),
 ('in', '0'),
 ('NY', 'O')]
```





#### Reference

- 1. Steven Bird, Ewan Klein, and Edward Loper, "Natural Language Processing with Python", 2009. #includes: Python + NLP + NLTK
- 2. Jacob Perkins, "Python Text Processing with NLTK 2.0 Cookbook", 2010.
- 3. Matthew A. Russell, "Mining the Social Web", 2011.
- 4. Loper, E., & Bird, S. (2002). NLTK: The Natural Language Toolkit. Proceedings of the ACL02 Workshop on Effective tools and methodologies for teaching natural language processing and computational linguistics.





# Thank you for your attention. Q & A

#### We are hiring!

- 核心引擎演算法研發工程師
- 系統研發工程師

本公司提供企業客戶語義分析服務。

• 網路應用研發工程師

獲創投"軟體銀行"投資與肯定。 歡迎對創業有熱情的你加入我們!

#### Oxygen Intelligence Taiwan Limited

引京聚點知識結構搜索股份有限公司

- 公司簡介: http://www.ezpao.com/about/
- 職缺簡介: http://www.ezpao.com/join/
- 請將履歷寄到 jimmy.lai@oi-sys.com



